

ggplot2

Jiayue LIU, Soukaina ELGHALDY

15 novembre 2020

Contents

Préparer les données	1
Nuage de points simples	2
Annoter les points	4
Ajouter des lignes de regression	5
Changer l'apparence des points et des traits	8
Nuage de points avec plusieurs groupes	10
Changer la couleur, le type, la taille des points automatiquement	10
Ajouter des droites de régression	13
Changer la couleur, le type, la taille des points manuellement	16
Ajouter la densité marginale	20
Nuage de points avec estimation de la densité 2d	23
Nuage de points avec ellipse	26
Nuage de point avec distribution marginale	29
Step 1/3 Créer des données:	29
Step 2/3 Créer des graphiques	29
Step 3/3 Regrouper les graphiques:	32
Nuages de points personnalisés	33
ggplot Cheat sheet	39

Ce Tuto décrit comment créer un nuage de point avec le package ggplot2

Préparer les données

Le jeu de données mtcars est utilisé dans les exemples ci-dessous

```
# convertir la colonne cyl en variable de type facteur
mtcars$cyl <- as.factor(mtcars$cyl)
head(mtcars)
```


```
##           mpg  cyl  disp  hp  drat    wt  qsec vs  am  gear  carb
## Mazda RX4   21.0    6  160 110 3.90 2.620 16.46  0   1    4    4
## Mazda RX4 Wag 21.0    6  160 110 3.90 2.875 17.02  0   1    4    4
```

```
## Datsun 710      22.8   4  108  93 3.85 2.320 18.61  1  1   4   1
## Hornet 4 Drive  21.4   6  258 110 3.08 3.215 19.44  1  0   3   1
## Hornet Sportabout 18.7   8  360 175 3.15 3.440 17.02  0  0   3   2
## Valiant         18.1   6  225 105 2.76 3.460 20.22  1  0   3   1
```


Nuage de points simples

Des nuages de points simples sont créés en utilisant le code de R ci-dessous. La couleur, la taille et la forme des points peuvent être modifiées en utilisant la fonction `geom_point()` comme suit: `geom_point(size, color, shape)`


```
#Nuage de points simple
ggplot(mtcars, aes(x=wt, y=mpg)) + geom_point()
```



```
# Changer la taille et la forme
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point(size=2, shape=23)
```



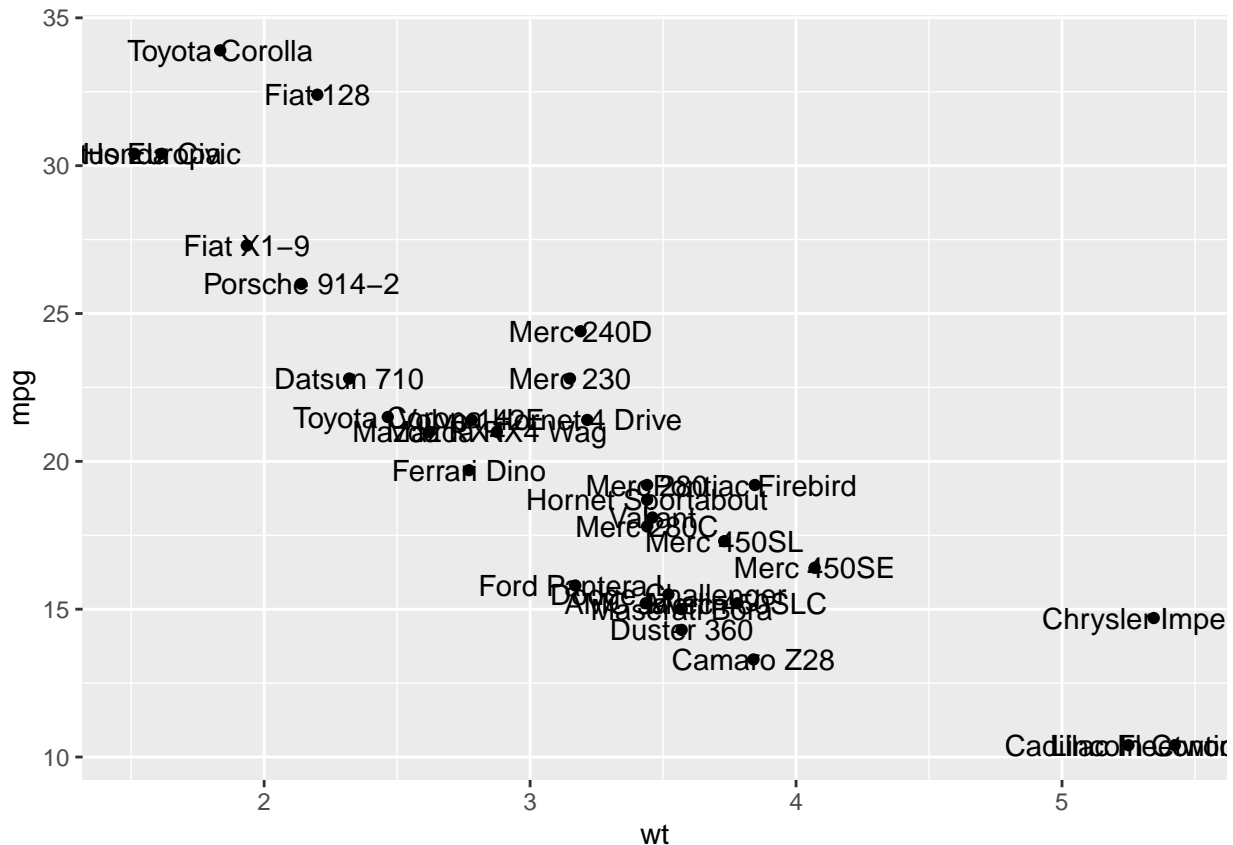
```
# Changer la taille des points  
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point(aes(size=qsec))
```



Annoter les points

La fonction `geom_text()` peut être utilisée :

```
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point() +  
  geom_text(label=rownames(mtcars))
```



Ajouter des lignes de regression


Les fonctions ci-dessous peuvent être utilisées pour ajouter des droites de régression à un nuage de points: `geom_smooth()` et `stat_smooth * geom_abline()` Seule la fonction `geom_smooth()` est couverte dans cette section.

Un format simplifié est: `geom_smooth(method="auto", se=TRUE, fullrange=FALSE, level=0.95)`

- **method** : méthode à utiliser pour estimer la tendance moyenne. Les valeurs possibles sont `lm`, `glm`, `gam`, `loess`, `rlm`.
- **se** : valeur logique. Si `TRUE`, l'intervalle de confiance est affichée autour de la moyenne.
- **fullrange** : valeur logique. Si `TRUE`, la courbe moyenne couvre le graphique en entier.
- **level** : niveau de l'intervalle de confiance à utiliser. La valeur par défaut est de 0,95.


```
# Ajouter la droite de regression
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point() +
  geom_smooth(method=lm)
```

```
## `geom_smooth()` using formula 'y ~ x'
```




```
# Supprimer l'intervalle de confiance  
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point()+  
  geom_smooth(method=lm, se=FALSE)
```

```
## `geom_smooth()` using formula 'y ~ x'
```



```
# La méthode "Loess"  
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point() +  
  geom_smooth()
```

```
## `geom_smooth()` using method = 'loess' and formula 'y ~ x'
```




Changer l'apparence des points et des traits

Cette section décrit comment modifier: *la couleur et la forme des points* le type de trait et la couleur de la droite de régression *la couleur de remplissage de l'intervalle de confiance


```
# Changer la couleur et la forme des points
# Changer le type de trait et la couleur
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point(shape=18, color="blue")+
  geom_smooth(method=lm, se=FALSE, linetype="dashed",
              color="darkred")
```

```
## `geom_smooth()` using formula 'y ~ x'
```

```
# Changer la couleur de remplissage de l'intervalle de confiance  
ggplot(mtcars, aes(x=wt, y=mpg)) +  
  geom_point(shape=18, color="blue")+  
  geom_smooth(method=lm, linetype="dashed",  
             color="darkred", fill="blue")
```

```
## `geom_smooth()` using formula 'y ~ x'
```




Nuage de points avec plusieurs groupes


Cette section décrit comment changer les couleurs et les types de points automatiquement et manuellement.

Changer la couleur, le type, la taille des points automatiquement

```
# Changer le type de points en fonction des niveaux de cyl  
ggplot(mtcars, aes(x=wt, y=mpg, shape=cyl)) +  
  geom_point()
```




```
# Changer le type et la couleur  
ggplot(mtcars, aes(x=wt, y=mpg, shape=cyl, color=cyl)) +  
  geom_point()
```



```
# Changer le type, la couleur et la taille  
ggplot(mtcars, aes(x=wt, y=mpg, shape=cyl, color=cyl, size=cyl)) +  
  geom_point()
```


```
## Warning: Using size for a discrete variable is not advised.
```



Ajouter des droites de régression


```
# Ajouter des lignes de régression  
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +  
  geom_point() +  
  geom_smooth(method=lm)
```

```
## `geom_smooth()` using formula 'y ~ x'
```



```
# Supprimer les intervalles de confiance
# Etendre les droites de régression
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +
  geom_point() +
  geom_smooth(method=lm, se=FALSE, fullrange=TRUE)
```


```
## `geom_smooth()` using formula 'y ~ x'
```



couleurs de remplissage des intervalles de confiances peuvent être changées comme suit:

```
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +  
  geom_point() +  
  geom_smooth(method=lm, aes(fill=cyl))
```


```
## `geom_smooth()` using formula 'y ~ x'
```



Changer la couleur, le type, la taille des points manuellement


```
# Changer le type de points et la couleur manuellement
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +
  geom_point() +
  geom_smooth(method=lm, se=FALSE, fullrange=TRUE)+
  scale_shape_manual(values=c(3, 16, 17))+
  scale_color_manual(values=c('#999999', '#E69F00', '#56B4E9'))+
  theme(legend.position="top")
```

```
## `geom_smooth()` using formula 'y ~ x'
```

```
# Changer la taille des points manuellement
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl))+
  geom_point(aes(size=cyl)) +
  geom_smooth(method=lm, se=FALSE, fullrange=TRUE)+
  scale_shape_manual(values=c(3, 16, 17))+
  scale_color_manual(values=c('#999999', '#E69F00', '#56B4E9'))+
  scale_size_manual(values=c(2,3,4))+
  theme(legend.position="top")
```


```
## `geom_smooth()` using formula 'y ~ x'
```



Il est également possible de modifier manuellement la couleur des points et des traits en utilisant les fonctions: * `scale_color_brewer()` : pour utiliser les palettes de couleurs du package RColorBrewer * `scale_color_grey()` : pour utiliser les palettes de couleurs grises


```
p <- ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +
  geom_point() +
  geom_smooth(method=lm, se=FALSE, fullrange=TRUE)+
  theme_classic()
# Utiliser les palettes brewer
p+scale_color_brewer(palette="Dark2")

## `geom_smooth()` using formula 'y ~ x'
```



```
# Utiliser les couleurs grises
p + scale_color_grey()

## `geom_smooth()` using formula 'y ~ x'
```




Ajouter la densité marginale


La fonction `geom_rug()` peut être utilisée: `geom_rug(sides = "bl")`

`sides` : côté sur lequel il faudrait ajouter la densité. La valeur possible est une chaîne de caractère contenant l'un des éléments "trbl", pour top (haut), right (droite), bottom (bas), et left (gauche).


```
# Ajouter la densité marginale
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point() + geom_rug()
```



```
# Changer les couleurs  
ggplot(mtcars, aes(x=wt, y=mpg, color=cyl)) +  
  geom_point() + geom_rug()
```




```
# Utiliser le jeu de données faithful
ggplot(faithful, aes(x=eruptions, y=waiting)) +
  geom_point() + geom_rug()
```



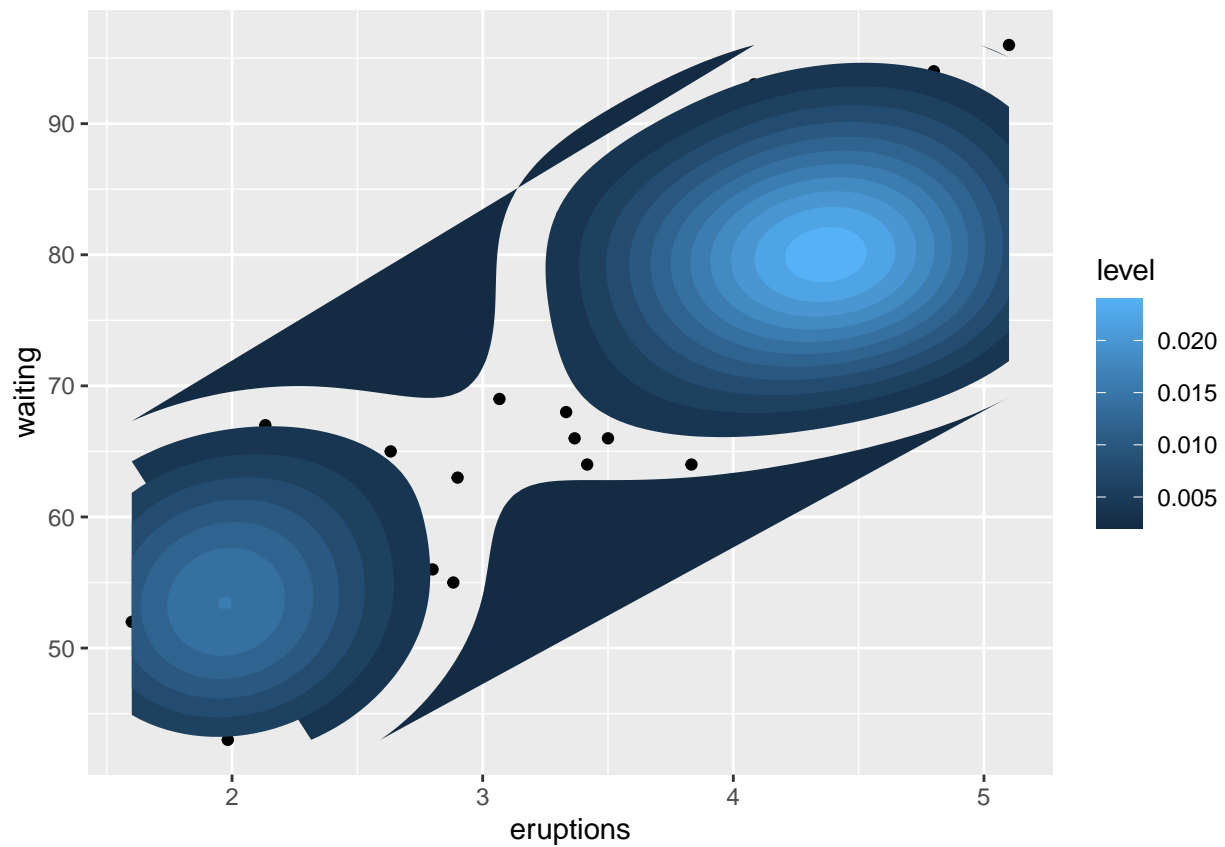
Nuage de points avec estimation de la densité 2d

Les fonctions `geom_density2d()` ou `stat_density2d()` peuvent être utilisées:


```
# Nuage de points avec estimation de la densité 2d
sp <- ggplot(faithful, aes(x=eruptions, y=waiting)) +
  geom_point()
sp + geom_density2d()
```



```
# Gradient de couleur  
sp + stat_density2d(aes(fill = ..level..), geom="polygon")
```


```
# Changer le gradient de couleur
sp + stat_density2d(aes(fill = ..level..), geom="polygon")+
  scale_fill_gradient(low="blue", high="red")
```




Nuage de points avec ellipse

La fonction `stat_ellipse()` peut être utilisée comme suit:


```
# Une ellipse autour de tous les points  
ggplot(faithful, aes(waiting, eruptions))+  
  geom_point()+  
  stat_ellipse()
```



```
# Ellipses par groupes  
p <- ggplot(faithful, aes(waiting, eruptions, color = eruptions > 3))+  
  geom_point()  
p + stat_ellipse()
```



```
# Changer le type d'ellipses:  
# Valeurs possibles "t", "norm", "euclid"  
p + stat_ellipse(type = "norm")
```



Nuage de point avec distribution marginale

Step 1/3 Créer des données:


```
set.seed(1234)
x <- c(rnorm(500, mean = -1), rnorm(500, mean = 1.5))
y <- c(rnorm(500, mean = 1), rnorm(500, mean = 1.7))
group <- as.factor(rep(c(1,2), each=500))
df <- data.frame(x, y, group)
head(df)
```

```
##           x           y group
## 1 -2.20706575 -0.2053334     1
## 2 -0.72257076  1.3014667     1
## 3  0.08444118 -0.5391452     1
## 4 -3.34569770  1.6353707     1
## 5 -0.57087531  1.7029518     1
## 6 -0.49394411 -0.9058829     1
```


Step 2/3 Créer des graphiques

```
# Nuage de points colorés par groupes
scatterPlot <- ggplot(df, aes(x, y, color=group)) +
```


```
geom_point() +
scale_color_manual(values = c('#999999','#E69F00')) +
theme(legend.position=c(0,1), legend.justification=c(0,1))
scatterPlot
```



```
# Courbe de densité marginale de x (panel du haut)
xdensity <- ggplot(df, aes(x, fill=group)) +
  geom_density(alpha=.5) +
  scale_fill_manual(values = c('#999999','#E69F00')) +
  theme(legend.position = "none")
xdensity
```



```
# Courbe de densité marginale de y (panel de droite)
ydensity <- ggplot(df, aes(y, fill=group)) +
  geom_density(alpha=.5) +
  scale_fill_manual(values = c('#999999', '#E69F00')) +
  theme(legend.position = "none")
ydensity
```






Créer un emplacement vide :

```
blankPlot <- ggplot()+geom_blank(aes(1,1))+
  theme(plot.background = element_blank(),
        panel.grid.major = element_blank(),
        panel.grid.minor = element_blank(),
        panel.border = element_blank(),
        panel.background = element_blank(),
        axis.title.x = element_blank(),
        axis.title.y = element_blank(),
        axis.text.x = element_blank(),
        axis.text.y = element_blank(),
        axis.ticks = element_blank()
  )
```

Step 3/3 Regrouper les graphiques:

Pour mettre plusieurs graphiques sur la même page, le package `gridExtra` peut être utilisé. Arranger le graphique avec des largeurs et des hauteurs adaptées pour chaque ligne et chaque colonne:


```
library(gridExtra)
grid.arrange(xdensity, blankPlot, scatterPlot, ydensity,
             ncol=2, nrow=2, widths=c(4, 1.4), heights=c(1.4, 4))
```

Nuages de points personnalisés


```
# Nuage de points simple
ggplot(mtcars, aes(x=wt, y=mpg)) +
  geom_point()+
  geom_smooth(method=lm, color="black")+
  labs(title="Miles per gallon \n according to the weight",
        x="Weight (lb/1000)", y = "Miles/(US) gallon")+
  theme_classic()
```

```
## `geom_smooth()` using formula 'y ~ x'
```



```
# Changer la couleur/ le type par groupe
# Supprimer l'intervalle de confiance
p <- ggplot(mtcars, aes(x=wt, y=mpg, color=cyl, shape=cyl)) +
  geom_point()+
  geom_smooth(method=lm, se=FALSE, fullrange=TRUE)+
  labs(title="Miles per gallon \n according to the weight",
        x="Weight (lb/1000)", y = "Miles/(US) gallon")
p + theme_classic()


## `geom_smooth()` using formula 'y ~ x'
```




Changer les couleurs manuellement

```
# Couleurs continues
p + scale_color_brewer(palette="Paired") + theme_classic()
```


```
## `geom_smooth()` using formula 'y ~ x'
```



```
# Couleurs discrètes  
p + scale_color_brewer(palette="Dark2") + theme_minimal()  
  
## `geom_smooth()` using formula 'y ~ x'
```



```
# Couleurs en gradient  
p + scale_color_brewer(palette="Accent") + theme_minimal()  
  
## `geom_smooth()` using formula 'y ~ x'
```



ggplot Cheat sheet

Data Visualization with ggplot2 :: CHEAT SHEET



Basics

ggplot2 is based on the **grammar of graphics**, the idea that you can build every graph from the same components: a **data set**, a **coordinate system**, and **geoms**—visual marks that represent data points.



To display values, map variables in the data to visual properties of the geom (**aesthetics**) like **size**, **color**, and **x** and **y** locations.



Complete the template below to build a graph.

```
ggplot (data = <DATA>) +  
  <GEOM_FUNCTION> (mapping = aes(<MAPPINGS>),  
    stat = <STAT>, position = <POSITION>) +  
  <COORDINATE_FUNCTION> +  
  <FACET_FUNCTION> +  
  <SCALE_FUNCTION> +  
  <THEME_FUNCTION>
```

ggplot(data = mpg, aes(x = ct, y = hwy)) Begins a plot that you finish by adding layers to. Add one geom function per layer.

geom(x = ct, y = hwy, data = mpg, geom = "point") Creates a complete plot with given data, geom, and mappings. Supplies many useful defaults.

last_plot() Returns the last plot

ggsave("plot.png", width = 5, height = 5) Saves last plot as 5" x 5" file named "plot.png" in working directory. Matches file type to file extension.

Geoms

Use a geom function to represent data points, use the geom's aesthetic properties to represent variables. Each function returns a layer.

GRAPHICAL PRIMITIVES

a <- ggplot(economics, aes(date, unemployment))
b <- ggplot(seals, aes(x = long, y = lat))

a + geom_blank()
(Useful for expanding limits)

b + geom_curve()
aes(yend = lat + 1, xend = long + 1, curvature = 1) - x, yend, y, alpha, angle, color, curvature, linetype, size

a + geom_path()
lineend = "butt", linejoin = "round", lineintre = 1
x, y, alpha, color, group, linetype, size

a + geom_polygon()
aes(group = group)
x, y, alpha, color, fill, group, linetype, size

b + geom_rect()
aes(ymin = long, ymax = lat, xmin = long + 1, xmax = lat + 1) - xmax, xmin, ymax, ymin, alpha, color, fill, linetype, size

a + geom_ribbon()
aes(ymin = unemployment - 900, ymax = unemployment + 900) - x, ymax, ymin, alpha, color, fill, group, linetype, size

LINE SEGMENTS

common aesthetics: x, y, alpha, color, linetype, size

b + geom_abline()
aes(intercept = 0, slope = 1)
b + geom_hline()
aes(yintercept = lat)
b + geom_vline()
aes(xintercept = long)

b + geom_segment()
aes(yend = lat + 1, xend = long + 1)
b + geom_spoke()
aes(angle = 1.1155, radius = 1)

ONE VARIABLE continuous

c <- ggplot(mpg, aes(hwy)); c2 <- ggplot(mpg)

c + geom_area()
stat = "bin"
x, y, alpha, color, fill, linetype, size

c + geom_density()
kernel = "gaussian"
x, y, alpha, color, fill, group, linetype, size, weight

c + geom_dotplot()
x, y, alpha, color, fill

c + geom_freqpoly()
x, y, alpha, color, group, linetype, size

c + geom_histogram()
binwidth = 5
x, y, alpha, color, fill, linetype, size, weight

c2 + geom_qq()
aes(sample = hwy)
x, y, alpha, color, fill, linetype, size, weight

discrete

d <- ggplot(mpg, aes(fill))

d + geom_bar()
x, alpha, color, fill, linetype, size, weight

TWO VARIABLES

continuous x, continuous y
e <- ggplot(mpg, aes(cty, hwy))

e + geom_label()
aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

e + geom_jitter()
height = 2, width = 2
x, y, alpha, color, fill, shape, size

e + geom_point()
x, y, alpha, color, fill, shape, size, stroke

e + geom_quantile()
x, y, alpha, color, group, linetype, size, weight

e + geom_rug()
sides = "bl"
x, y, alpha, color, linetype, size

e + geom_smooth()
method = "lm"
x, y, alpha, color, fill, group, linetype, size, weight

e + geom_text()
aes(label = cty), nudge_x = 1, nudge_y = 1, check_overlap = TRUE
x, y, label, alpha, angle, color, family, fontface, hjust, lineheight, size, vjust

discrete x, continuous y

f <- ggplot(mpg, aes(class, hwy))

f + geom_col()
x, y, alpha, color, fill, group, linetype, size

f + geom_boxplot()
x, y, lower, middle, upper, ymax, ymin, alpha, color, fill, group, linetype, shape, size, weight

f + geom_dotplot()
binaxis = "y", stackdir = "center"
x, y, alpha, color, fill, group

f + geom_violin()
scale = "area"
x, y, alpha, color, fill, group, linetype, size, weight

discrete x, discrete y

g <- ggplot(diamonds, aes(cut, color))

g + geom_count()
x, y, alpha, color, fill, shape, size, stroke

THREE VARIABLES

seals2 <- with(seals, sqrt(delta_long*2 + delta_lat*2)); i <- ggplot(seals, aes(long, lat))

i + geom_contour()
aes(z = z)
x, y, z, alpha, colour, group, linetype, size, weight

i + geom_raster()
aes(fill = z), hjust = 0.5, vjust = 0.5, interpolate = FALSE
x, y, alpha, fill

i + geom_tile()
aes(fill = z), x, y, alpha, color, fill, linetype, size, width

continuous bivariate distribution

h <- ggplot(diamonds, aes(carat, price))

h + geom_bin2d()
binwidth = c(0.25, 500)
x, y, alpha, color, fill, linetype, size, weight

h + geom_density2d()
x, y, alpha, colour, group, linetype, size

h + geom_hex()
x, y, alpha, colour, fill, size

continuous function

i <- ggplot(economics, aes(date, unemployment))

i + geom_area()
x, y, alpha, color, fill, linetype, size

i + geom_line()
x, y, alpha, color, group, linetype, size

i + geom_step()
direction = "hv"
x, y, alpha, color, group, linetype, size

visualizing error

df <- data.frame(grp = c("A", "B"), fit = 4.5, se = 1.2)
j <- ggplot(df, aes(grp, fit, ymin = fit-se, ymax = fit+se))

j + geom_crossbar()
fatten = 2
x, y, ymax, ymin, alpha, color, fill, group, linetype, size

j + geom_errorbar()
x, ymax, ymin, alpha, color, group, linetype, size, width (also **geom_errorbarh()**)

j + geom_linerange()
x, ymin, ymax, alpha, color, group, linetype, size

j + geom_pointrange()
x, y, ymin, ymax, alpha, color, fill, group, linetype, shape, size

maps

data <- data.frame(murder = USArrests\$Murder, state = tolower(rownames(USArrests)))
map <- map_data("state")
k <- ggplot(data, aes(fill = murder))

k + geom_map()
aes(map_id = state), map = map)
+ expand_limits(~ map\$long, y = map\$lat)
map_id, alpha, color, fill, linetype, size



